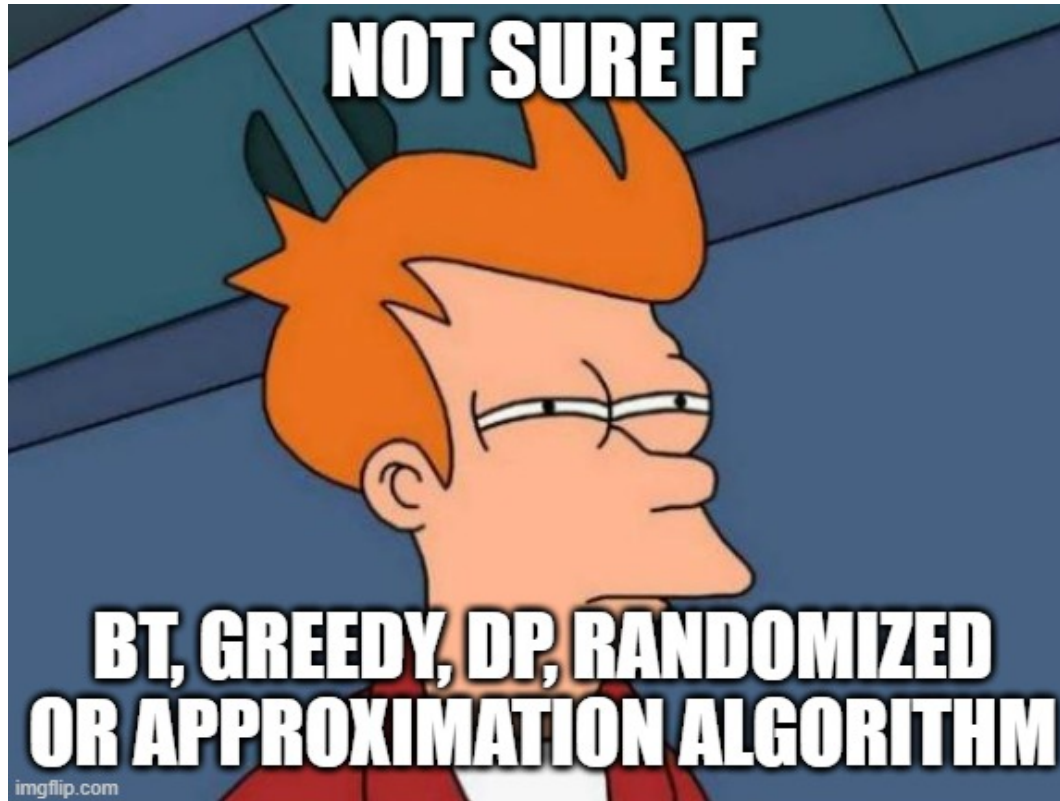


Algoritmos y complejidad



Ayudantía 10

Temario

- Repaso Programación Dinámica
 - 0-1 Knapsack problem
- Algoritmos aproximados
 - Traveling Salesman Problem
- Polynomial approximation schemes
 - Subset sum

Programación dinámica

- Aplicamos la estrategia dividir y conquistar cuando podemos separar un problema en subproblemas. La idea es resolver los problemas recursivamente y luego combinar las soluciones.
- Cuando estos subproblemas se solapan y terminamos solucionando los mismos una y otra vez es mejor utilizar **programación dinámica**.
- Es un método para resolver problemas (de optimización generalmente) con un enfoque Bottom-up; cuando una solución se requiera ya estará calculada. ❤️

Recordar Fibonnaci, o Dijkstra.

Cuándo podemos aplicarla?

Necesitamos que el problema cumpla dos propiedades:

1. Optimal substructure: Mediante óptimos para subproblemas, se puede llegar a un óptimo para el problema general.
2. Overlapping problems.

Cormen, T., Leiserson, C., Rivest, R., & Stein, C. (s. f.).
Introduction to algorithms (3.a ed.). MIT Press. ❤️

0-1 Knapsack problem

- Consideremos una mochila con capacidad máxima W .
- Tenemos n items, cada item i tiene un valor v_i y un peso w_i asociado.
- Cada item, lo podemos llevar o no. No podemos tomar una fracción de él. 🤔

- Buscamos maximizar $\sum_{i=0}^n v_i$ sujeto a $\sum_{i=0}^n w \leq W$.

- La idea será construir una matriz $V[0..n, 0..W]$.

Memoization data structure.

- El elemento $V[i, j]$ almacena el **máximo valor** para cualquier subconjunto de items $\{1 \dots i\}$ que **pueden caber** en una mochila de capacidad j .
- Notar que la solución vendrá dada por $V[n, W]$.
- Notar que $V[0, j] = 0, \forall j \in 1 \dots W$.

Para cada item i , podemos considerarlo o no:

- Si lo consideramos, el valor óptimo vendrá dado por cómo llenar la mochila de capacidad $j - w_i$ con los items restantes $\{1, \dots, i - 1\}$:

$$v_i + V[i - 1, j - w_i]$$

- De lo contrario, el valor óptimo vendrá dado por cómo llenar la mochila de capacidad j con los items restantes $\{1, \dots, i - 1\}$:


$$V[i - 1, j]$$

- Asi, obtenemos la siguiente recurrencia:

$$V[i, j] = \begin{cases} V[i - 1, j] & \text{if } w_i > j \\ \max(v_i + V[i - 1, j - w_i], V[i - 1, j]) & \text{if } w_i \leq j \end{cases}$$

- Ademas, sabemos $V[0, j] = 0$

Si no tenemos items, entonces no tendremos ningún valor asociado.

- Contamos con una recurrencia. Los siguientes pasos son estandar para disenar el algoritmo basado en DP:
 1. Formular el problema recursivamente. 
 2. Identificar subproblemas.
 3. Elegir la estructura de datos para la memoización.
 4. Identificar dependencias.
 5. Encontrar un buen orden de evaluación.
 6. Analizar la complejidad espacial y temporal.
 7. Escribir el algoritmo.

Solución en Python

```
def solve_knapsack(v,w,n,W):  
    V = np.zeros((n, W))  
    for i in range(1, n):  
        for j in range(W):  
            leave_val = V[i - 1][j]  
            if( j >= w[i]):  
                take_val = v[i] + V[i - 1][j - w[i]]  
            else:  
                take_val = - np.inf  
            V[i][j] = max(leave_val, take_val)  
    return V[n - 1][W - 1]
```

Algoritmos aproximados

Definicion

Algoritmo con tiempo de ejecución polinomial idealmente, que produce una solución que está garantizada a estar dentro de un factor de optimalidad. ❤️

Decimos que un algoritmo para un problema de tamaño n tiene un ratio de aproximación $\rho(n)$, si para cada input produce una solución con costo C tal que:

$$\max\left(\frac{C}{C^*}, \frac{C^*}{C}\right) \leq \rho(n)$$

Donde C^* es el costo óptimo.

$\rho(n)$ puede ser constante, o bien una función creciente. Notar que hablamos de costos debido a el enfoque hacia los problemas de optimización.

¿Por qué algoritmos aproximados?

- Estamos interesados en aproximar soluciones a problemas NP completos con algoritmos polinomiales.
- Plantearemos una heurística greedy interesante y demostraremos que en cualquier caso obtendremos una solución dentro de un factor de optimalidad.
- Por ejemplo, para un problema de minimización podríamos obtener un algoritmo que entrega un resultado que es a lo más el doble del óptimo.

Idea general

1. Definir el problema.
2. Pensar en una heurística interesante.
3. Demostrar el factor de optimalidad.

Las demostraciones ya no serán (tan) complicadas (en general).

Traveling Salesman Problem

Enunciado

- $G(U, V)$ grafo no dirigido rotulado con pesos positivos dados por la función $w(u, v)$.
- Buscamos un ciclo C que visite todos los vértices de G al mínimo costo $W(C)$: la suma de los costos de todos los arcos en C .
- Consideremos $w(u, v) \leq w(u, x) + w(x, v)$.

Para ir de un nodo al otro, el mejor camino siempre sera el directo.

Aproximación

- Sea C^* el ciclo óptimo para el TSP, al eliminar uno de sus arcos obtenemos un árbol recubridor (spanning tree).
- $W(C^*)$ es a lo menos $W(T)$, con T el árbol recubridor mínimo.

$$W(T) \leq W(C^*)$$

- De que forma podemos utilizar esto para obtener un algoritmo aproximado que resuelva TSP?

- La idea será pararnos en un vertice u y realizar un viaje de ida y vuelta en T .
- Este viaje tiene un costo de $2 \cdot W(T)$.
- Buscamos un ciclo C en donde solo se repita el nodo inicial, nuestro viaje tiene nodos repetidos dos veces.
- Necesitamos $W(C) \leq 2 \cdot W(T)$.
- Así, tendríamos $W(C) \leq 2 \cdot W(T) \leq 2 \cdot W(C^*)$.

- Para eliminar los nodos de nuestro viaje **ida y vuelta** y así formar C recordemos $w(u, v) \leq w(u, x) + w(x, v)$.
- Podemos partir en cualquier nodo u y "tratar de seguir" el viaje ida y vuelta. Cada vez que debamos devolvernó a un nodo x para ir a v desde u , lo haremos directamente (sin los nodos intermedios).

- Esta estrategia garantiza que encontramos un ciclo C tal que $W(C) \leq 2 \cdot W(T)$ debido a nuestro supuesto. 🙏
- Como ya sabemos $2 \cdot W(T) \leq W(C)$, obtenemos:

$$\frac{W(C)}{W(C^*)} \leq 2$$

- Nuestro algoritmo tiene un ratio de aproximación constante de 2. A lo más tendremos una solución que es el doble del óptimo. 🤔

Pseudocódigo

```
def approx_TSP(G):  
    T = kruskal(G) # arbol recubridor minimo  
    u = select_initial_node(T)  
    C = pre_order(u,T) # analogo a nuestra tecnica  
    return C
```

Polynomial time approximation schemes (PTAS)

- Con algoritmos aproximados obtenemos soluciones dentro de un factor de optimalidad.
- Nos gustaria poder controlar la precisión. Esto lo haremos mediante un input $\epsilon > 0$ que garantizará una solución con error relativo de a lo más ϵ .
- A medida que ϵ tiende a 0, tendremos un algoritmo con un mayor tiempo de ejecución. Por ejemplo un algoritmo con complejidad $O(2^{1/\epsilon} n^2)$.

- Un **fully polynomial time approximation scheme** (FPTAS) es un algoritmo cuyo tiempo de ejecución es polinomial para n y $1/\epsilon$. Por ejemplo un algoritmo con complejidad $O((n/\epsilon)^2)$
- Para tales casos aproximaciones razonablemente precisas son computacionalmente factibles. ❤️
- Lamentablemente muy pocos problemas NP completos admiten este tipo de algoritmos. 🙄

Subset sum

- Sea S un conjunto de enteros positivos $\{x_1, \dots, x_n\}$, y s un valor objetivo.
- Buscamos el subconjunto $S' \subseteq S$ tal que la suma de sus elementos sea exactamente o menor a s , pero no mayor.

Algoritmo determinista

- Un algoritmo no muy eficiente para este problema es el siguiente:

```
def subset_sum(l, suma):  
    s = set([0])  
    for i in range(0, len(l)):  
        s = s | set(map(lambda x: x + l[i], s))  
        s = set(filter(lambda x: x <= suma, s))  
    return max(s)
```

- El tiempo de ejecución viene dado por $\Omega(2^n)$.

Debido a que se analiza el conjunto potencia de un arreglo de n elementos.

- Para una ejecución con $l = [1, 4, 6]$ y suma 8, se obtiene:

$$s_0 = [0]$$

$$s_1 = [0] \cup [0 + 1] = [0, 1]$$

$$s_2 = [0, 1] \cup [0 + 4, 1 + 4] = [0, 1, 4, 5]$$

$$\begin{aligned} s_3 &= [0, 1, 4, 5] \cup [0 + 6, 1 + 6, 4 + 6, 5 + 6] \\ &= [0, 1, 4, 5, 6, 7] \end{aligned}$$

- El optimo es 7.

Qué pasa si agregamos valores a l muy similares a los ya presentes?

Approximation algorithm

- La idea será "podar" elementos que sean **relativamente** cercanos.
- El optimo para $[1, 1.01, 4, 6, 6.2]$ es de 7.21, con la versión "podada" (trimmed) $[1, 4, 6]$ es 7. 🤔
- Qué tanto podemos podar (disminuir el espacio de búsqueda) manteniendo una solución **suficientemente** buena? 🤔
- Podemos reducir el espacio de búsqueda de exponencial en n a lineal? 🤔

- El error relativo que estamos dispuestos a asumir es ϵ .
- Qué tanto podemos podar viene dado por $\delta = \frac{\epsilon}{n}$, notar que $0 < \delta < 1$
- Asumiendo L ordenado, iteraremos sobre la lista.
- Sea z el último elemento no podado en L e $y \geq z$ el siguiente elemento. Podaremos a y si:

$$\frac{y - z}{y} \leq \delta$$

- Es decir, en L no habrán elementos y y z tal que:

$$(1 - \delta)y \leq z \leq y$$

- Al podar estamos forzando que no hayan elementos muy similares en L .
- Considere $L = [10, 11, 12, 15, 20, 21, 22, 23, 24, 29]$, al podar obtenemos $L = [10, 12, 15, 20, 23, 29]$ con $\delta = 0.1$.

- Agregando la función trim que se encarga de podar en cada iteración, obtenemos el siguiente algoritmo PTAS:

```
def app_subset_sum(l, suma, epsilon):  
    s = set([0])  
    delta = epsilon/len(l)  
    for i in range(0, len(l)):  
        s = s | set(map(lambda x: x + l[i], s))  
        aux = list(s)  
        aux.sort()  
        s = set(trim(aux, delta))  
        s = set(filter(lambda x: x <= suma, s))  
    return max(s)
```

```
def trim(l, delta):  
    l_prime = [l[0]]  
    last = l[0]  
    for i in range(1, len(l)):  
        if (last < (1 - delta) * l[i]):  
            l_prime.append(l[i])  
            last = l[i]  
    return l_prime
```

Analisis alternativo

- La idea será ver la acción de podar (trimming) como dividir el intervalo $[1 \dots s]$ en subintervalos de largo exponencialmente creciente.
- Sea $d = 1/(1 - \delta)$ (notar $d > 1$) y consideramos los intervalos:

$$[1, d], [d, d^2], [d^2, d^3], \dots, [d^{k-1}, d^k]$$

donde $d^k \geq s$.

- Notemos que si y y $z \leq y$ están en el mismo subintervalo $[d^{n-1}, d^n]$ entonces:

$$\frac{y - z}{y} \leq \frac{d^n - d^{n-1}}{d^n} = 1 - \frac{1}{d} = \delta$$

- Es congruente con lo planteado anteriormente.
- Entonces, visto de esta manera al hacer trimming no tendremos más de un elemento en un mismo subintervalo.

Demostración PTAS

- Debemos demostrar que el tiempo de ejecución es polinomial en n .
- Primero demostraremos que el tamaño de la lista podada (trimmed) es $O((n \cdot \log s)/\epsilon)$
- Cualquier par consecutivo de datos difieren al menos por un ratio $d = 1/(1 - \delta)$. Pues:

$$\begin{aligned}\frac{y - z}{y} &\leq \delta = 1 - \frac{1}{d} \\ 1 - \frac{z}{y} &\leq 1 - \frac{1}{d} \\ \frac{z}{y} &\geq \frac{1}{d}\end{aligned}$$

- El elemento no cero más pequeño difiere del máximo por un ratio de al menos d^{k-1} , con k el número de elementos en la lista podada.
- Como el elemento no cero más pequeño es al menos 1, y el máximo a lo más s tenemos que:

$$d^{k-1} \leq s/1$$

- Tomando logaritmo natural obtenemos:

$$(k - 1) \ln d \leq \ln s$$

- Sabemos $\delta = \epsilon/n$, además utilizaremos la identidad $\ln(1 + x) \leq x$.

- Así tenemos:

$$k - 1 \leq \frac{\ln s}{\ln d} = \frac{\ln s}{-\ln(1 - \delta)} \leq \frac{\ln s}{\delta} = \frac{n \ln s}{\epsilon}$$

- Concluimos complejidad espacial $k = O(\frac{n \log s}{\epsilon})$.
- El tiempo de ejecución sera $O(n \cdot k) = O(\frac{n^2 \ln s}{\epsilon})$

n debido a las iteraciones y $\frac{n \ln s}{\epsilon}$ como cota superior al tamaño de la lista a la cual aplicaremos la función trim.

Conclusiones

- Aproximamos un algoritmo determinista con complejidad temporal (y espacial) exponencial, con un algoritmo con complejidad temporal (y espacial) lineal en n . Esto ha sido demostrado.
- Demostramos que la solución efectivamente cumple con el máximo error ϵ que asumimos? ... 🥵, no. Esta demostración es también necesaria.
- La demostración restante se puede encontrar en el siguiente documento, en el cual se basó fuertemente esta ayudantía:

<https://www.cs.umd.edu/class/fall2013/cmsc451/Lects/cmsc451-fall13-lects.pdf> ❤️

- Contamos con un set de estrategias para diseñar algoritmos:
 - i. Dividir y conquistar.
 - ii. Backtracking.
 - iii. Greedy.
 - iv. Programacion dinámica.
 - v. Algoritmos Aleatorizados.
 - vi. Algoritmos Aproximados
- El documento citado contiene las todas estrategias 🤪, un verdadero tesoro.